# AIPerf: Meta 构建覆盖架构设计，竞争分析，硅设计，部署，模型协同设计的统一性能建模仿真平台，精度 94%

**洞察启示**

- 洞察 | 跨平台、跨阶段的一致性性能建模比绝对精度更重要， plan-ranking 保真度与 gap 归因是生产级规划器的关键能力
- 启发 | 我们也需要构建端到端的仿真平台，覆盖自研芯片与友商竞品对比，实现模型负载到整机芯片的架构寻优，为下一代自研芯片与整机规划提供依据

**①问题描述**

- 超大规模集群下， LLM 与 AI Infra 协同设计是一项核心难题
- 模型迭代日新月异，而硬件方案的决策却需要数年前置周期，二者节奏错位会导致 AI 体系出现严重效率损耗
- Meta 将一个超过 10,000 个 CPU 核的集群专门用于

Figure

**②AIPerf 是一套性能建模框架，在六阶段模型 - 硬件协同设计生命周期中提供决策支撑**

- 每阶段现实挑战：跨平台对标竞争分析、并行策略配置、随负载变化的机架规划等
- 刻画覆盖架构设计，竞争分析，硅设计，部署，模型协同设计
- 支持联合 5D 并行搜索（TP/PP/CP/EF+ 数据并行）如下图
- 引入调度感知时序建模与跨平台可重定向的模块化架构
- 覆盖 MoE 路由

Figure

**③技术收益**

- 端到端误差 6%：在 H100， GB300 上， 8 种并行配置下 4 个模型， AIPerf 预测与实测吻合

Figure

- 在 4K MTIA 400 集群对比 CLOS / 2D / 3D Torus， AIPerf 按拓扑寻优 5D 并行策略

Figure

**关键技术**

- 刻画覆盖架构设计、竞争分析、硅设计、部署、模型协同设计、轨迹设置的六阶段硬件 -AI 协同设计生命周期
- 提出 AIPerf 框架，支持联合 5D 并行搜索（TP/PP/CP/EP+ 数据并行）并带内存可行性剪枝
- 引入调度感知时序建模与跨平台可重定向的模块化架构，覆盖 MoE 路由不均衡等异构工作负载场景



*Source: MICRO 2026 – AIPerf: Meta's Performance Modeling and HW/SW Co-design Framework for Datacenter-Scale LLM Training, Meta [Industry Session]*